



TRAKYA ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

YAPAY SİNİR AĞLARINA GİRİŞ
PROJE RAPORU

PROJE ADI:

SLA İhlali Tahmini

PROJE EKİBİ:

1221602033-Azra Işık

1221602057-Dilara Alkan

1221602024-Kerem Altay

1221602045-Sena Kaçak

1221602614-Yağmur Saygı

PROJE DANIŞMANI:

Dr. Öğr. Üyesi Turgut Doğan

Edirne – 2026

İÇİNDEKİLER

1. GİRİŞ	4
1.1. Projenin Amacı.....	4
1.2. Problem Tanımı	4
1.3. Projenin Kapsamı	4
1.4. Karar Destek Sistemi Yaklaşımı	4
2. GEREKSİNİM ANALİZİ	5
2.1. Sistem Gereksinimleri	5
2.2. Veri Gereksinimleri	5
2.3. Hedef Kullanıcı Grubu	5
2.4. Kullanılan Teknolojiler	6
3. TASARIM	6
3.1. Sistem Mimarisi	6
3.2. Veri Akışı	7
3.3. Arayüz Tasarımı	7
3.4. Karar Destek Mekanizması	7
4. GELİŞTİRME	8
4.1. Veri Seti ve Ön İşleme	8
4.2. Kullanılan Özellikler	9
4.3. Denetimli Öğrenme Yaklaşımı	9
4.4. SLA İhlal Riski Sınıflandırma Modeli	10
4.5. Çözüm Süresi Regresyon Modeli	11
4.6. Yapay Sinir Ağı Modeli	11
4.7. Model Çıktılarının Arayüze Entegrasyonu	12
5. TEST VE DOĞRULAMA	13
5.1. Sınıflandırma Modeli Sonuçları	13
5.2. Regresyon Modeli Sonuçları	14
5.3. Yapay Sinir Ağı Model Sonuçları	15
5.4. Modellerin Karşılaştırılması	16

6. SONUÇ VE DEĞERLENDİRME	18
6.1. Proje Sonuçları	18
6.2. Yapay Sinir Ağları Açısından Değerlendirme	18
6.3. Sınırlılıklar ve Gelecek Çalışmalar	18
7. KAYNAKLAR	19
8. GİTHUB LİNKİ	20

1. GİRİŞ

1.1. Projenin Amacı

Bu projenin temel amacı, BT hizmet yönetimi süreçlerinde oluşan destek taleplerine ait verilerden yararlanarak SLA (Service Level Agreement) ihlal riskinin önceden tahmin edilmesi ve taleplerin çözüm süresinin öngörülmesidir. Bu doğrultuda makine öğrenmesi teknikleri kullanılarak hem sınıflandırma hem de regresyon modelleri geliştirilmiştir. Ayrıca, geliştirilen modellerin performansları karşılaştırılmış ve elde edilen sonuçlar karar destek sistemi yaklaşımı ile değerlendirilmiştir.

1.2. Problem Tanımı

Kurumsal sistemlerde destek taleplerinin zamanında çözülememesi, SLA ihlallerine neden olmakta ve hizmet kalitesini doğrudan etkilemektedir. Bu durum, müşteri memnuniyetinin düşmesine ve operasyonel verimliliğin azalmasına yol açmaktadır. Problemin temelinde, hangi taleplerin riskli olduğunun önceden belirlenememesi ve çözüm sürelerinin doğru şekilde tahmin edilememesi yer almaktadır. Bu proje, geçmiş verilerden öğrenerek bu belirsizliği azaltmayı ve daha etkin bir süreç yönetimi sağlamayı hedeflemektedir.

1.3. Projenin Kapsamı

Proje kapsamında, 242.901 satır ve 11 sütundan oluşan geniş bir incident yönetimi veri seti kullanılmıştır. Veri seti üzerinde analiz, ön işleme ve özellik mühendisliği çalışmaları gerçekleştirilmiş, ardından farklı makine öğrenmesi modelleri uygulanmıştır. Bu modeller arasında Random Forest, Logistic Regression ve Yapay Sinir Ağları yer almaktadır. Ayrıca, SLA ihlal tahminine ek olarak çözüm süresi tahmini de gerçekleştirilmiş ve sonuçlar karşılaştırmalı olarak değerlendirilmiştir.

1.4. Karar Destek Sistemi Yaklaşımı

Geliştirilen sistem yalnızca bir tahmin modeli olmanın ötesinde, karar destek sistemi olarak tasarlanmıştır. Sistem, gelen taleplerin SLA ihlal riskini hesaplayarak kritik durumları önceden belirlemekte ve yöneticilere önceliklendirme konusunda yardımcı olmaktadır. Bu

yaklaşım sayesinde kullanıcılar, veri temelli ve daha doğru kararlar alabilmekte, operasyonel süreçler daha etkin bir şekilde yönetilebilmektedir.

2. GEREKSİNİM ANALİZİ

2.1. Sistem Gereksinimleri

Projenin gerçekleştirilmesi için Python programlama dili kullanılmış olup, veri işleme ve modelleme süreçlerinde Pandas, NumPy, Scikit-learn ve TensorFlow/Keras kütüphanelerinden yararlanılmıştır. Ayrıca model performanslarının değerlendirilmesi ve görselleştirilmesi için Matplotlib ve Seaborn kütüphaneleri kullanılmıştır.

2.2. Veri Gereksinimleri

Projenin temel veri gereksinimi, IT servis yönetimi süreçlerine ait geçmiş incident kayıtlarıdır. SLA ihlal riskinin tahmin edilebilmesi için modelin geçmişte hangi taleplerin zamanında çözüldüğünü, hangi taleplerin SLA ihlali yaptığını ve bu taleplerin süreç içinde nasıl ilerlediğini öğrenmesi gerekmektedir. Bu nedenle olay bazlı incident yönetimi veri seti kullanılmıştır.

Veri setinde her destek talebine ait öncelik, problem türü, raporlama kanalı, zaman bilgileri, süreç adımları ve sorumlu değişimleri gibi bilgiler yer almaktadır. Bu bilgiler, talebin yalnızca başlangıç durumunu değil, süreç içindeki davranışını da analiz etmeye olanak sağlamaktadır.

Bunun yanında, model performansını artırmak amacıyla Step_count, Reassignment_count, Escalation_count, Workload_Index, Open_Hour ve Is_Weekend gibi yeni özellikler türetilmiştir. Bu özellikler, süreç davranışını daha iyi temsil ederek modelin öğrenme kapasitesini artırmaktadır.

2.3. Hedef Kullanıcı Grubu

Geliştirilen sistem, özellikle IT destek ekipleri, sistem yöneticileri ve operasyon yöneticileri için tasarlanmıştır. Bu kullanıcılar, sistem sayesinde hangi taleplerin riskli olduğunu önceden görebilmekte ve buna göre müdahale planı oluşturabilmektedir.

2.4. Kullanılan Teknolojiler

Projede veri işleme, modelleme, görselleştirme ve arayüz geliştirme amacıyla farklı Python kütüphaneleri kullanılmıştır. Pandas, CSV dosyalarının okunması ve veri çerçeveleri üzerinde işlem yapılması için kullanılmıştır. NumPy, sayısal hesaplamalarda destekleyici rol oynamıştır. Scikit-learn, Random Forest, Logistic Regression, veri bölme, metrik hesaplama, pipeline ve ColumnTransformer işlemleri için kullanılmıştır.

TensorFlow/Keras, yapay sinir ağı modelinin geliştirilmesinde kullanılmıştır. Keras ile çok katmanlı algılayıcı yapısı kurulmuş, modelde gizli katmanlar, aktivasyon fonksiyonları, dropout ve erken durdurma gibi bileşenler uygulanmıştır. Matplotlib ve Seaborn, model sonuçlarının grafiklerle desteklenmesi için tercih edilmiştir.

Streamlit ise son kullanıcı arayüzünün geliştirilmesini sağlamıştır. Arayüzde kullanıcıya risk skoru, risk seviyesi, tahmini çözüm süresi, SLA durumu ve önerilen aksiyon gibi karar destek çıktıları sunulmuştur. Model dosyalarının saklanması ve tekrar kullanılması için joblib, model konfigürasyon bilgilerinin yönetilmesi için ise JSON dosyaları kullanılmıştır.

3. TASARIM

3.1. Sistem Mimarisi

Sistem mimarisi üç ana katmandan oluşmaktadır. İlk katman veri katmanıdır. Bu katmanda ham incident kayıtları okunur, temizlenir ve modelin kullanabileceği yapıya dönüştürülür. Olay bazlı kayıtlar vaka düzeyinde özetlenir ve her destek talebi için süreç özellikleri oluşturulur.

İkinci katman model katmanıdır. Bu katmanda SLA ihlal riski tahmini için sınıflandırma modeli, çözüm süresi tahmini için regresyon modeli ve karşılaştırma amacıyla yapay sinir ağı modeli yer almaktadır. Sınıflandırma modeli, talebin SLA ihlali yapma olasılığını üretir. Regresyon modeli ise talebin yaklaşık kaç saat içinde çözülebileceğini tahmin eder.

Üçüncü katman arayüz katmanıdır. Bu katman Streamlit ile geliştirilmiştir. Arayüz, modelin teknik çıktılarını doğrudan göstermenin yerine bu çıktıları son kullanıcı için anlaşılır hale getirir. Kullanıcı, arayüzde analiz edilen dosya sayısını, risk seviyelerini, tahmini süreleri, SLA durumunu ve önerilen aksiyonları görebilmektedir.

3.2. Veri Akışı

Veri seti: <https://www.kaggle.com/datasets/albertopmd/process-mining-event-log-incident-management>

(Incident_Management_CSV.csv)

Veri akışı süreci, veri setinin okunması ile başlamaktadır. Ardından veri temizleme ve dönüştürme işlemleri gerçekleştirilmekte, elde edilen veri pipeline yapısı ile modele uygun hale getirilmektedir. Daha sonra eğitim ve test verileri oluşturulmakta ve model bu veriler üzerinde eğitilmektedir. Son aşamada model tahminleri alınarak performans değerlendirmesi yapılmaktadır.

3.3. Arayüz Tasarımı

Projede geliştirilen arayüz sayesinde kullanıcılar model çıktıları ile etkileşime geçebilmektedir.

Arayüzde üst bölümde genel durum kartları bulunmaktadır. Bu kartlarda analiz edilen dosya sayısı, yüksek riskli dosya sayısı, ortalama tahmini çözüm süresi, ortalama risk oranı ve kritik öncelikli kayıt sayısı gösterilmektedir. Bu yapı, yöneticinin genel operasyon durumunu hızlıca görmesini sağlar.

Ana tabloda öncelikli takip listesi yer almaktadır. Bu listede her dosya için dosya numarası, öncelik, problem türü, SLA ihlal riski, risk seviyesi, tahmini çözüm süresi, SLA limiti, SLA durumu ve önerilen aksiyon bilgileri gösterilmektedir. Dosya detay ekranında ise seçilen talebe ait süreç özellikleri, tahmini süre, SLA farkı ve riskin olası nedenleri daha ayrıntılı biçimde sunulmaktadır.

3.4. Karar Destek Mekanizması

Karar destek mekanizması, sınıflandırma ve regresyon modeli çıktılarının birlikte değerlendirilmesine dayanmaktadır. SLA ihlal riski modeli, her destek talebi için bir risk olasılığı üretir. Bu olasılık, belirlenen eşiklere göre düşük, orta veya yüksek risk seviyesine dönüştürülür.

Çözüm süresi modeli ise talebin tahmini çözüm süresini saat cinsinden hesaplar. Bu değer, talebin Priority seviyesine göre belirlenen SLA limiti ile karşılaştırılır. Örneğin High öncelikli

bir talep için SLA limiti daha düşükken, Low öncelikli bir talep için daha yüksek olabilir. Tahmini çözüm süresi SLA limitini aşıyorsa sistem bu talebi riskli olarak yorumlar.

Önerilen aksiyon alanı, model çıktılarının günlük operasyon sürecine aktarılmasını sağlar. Eğer tahmini süre SLA limitini aşıyorsa ek kaynak veya yönetici desteği önerilir. Yeniden atama sayısı yüksekse dosya sahibinin sabitlenmesi, iş yükü yüksekse iş yükünün yeniden dağıtılması, üst destek yönlendirmesi varsa yönetici kontrolü önerilebilir. Böylece model çıktısı yalnızca sayısal bir sonuç olarak kalmaz, kullanıcıya uygulanabilir bir yönlendirme sunar.

4. GELİŞTİRME

4.1. Veri Seti ve Ön İşleme

Projede kullanılan ham veri seti incident yönetimi kayıtlarından oluşmaktadır. Ham kayıtlar olay bazlıdır ve aynı destek talebine ait birden fazla event satırı bulunabilmektedir. Bu nedenle modelleme öncesinde verinin vaka düzeyine dönüştürülmesi gerekmiştir. Her bir Case ID için süreç geçmişini incelenmiş ve destek talebini temsil eden özet değişkenler oluşturulmuştur.

Veri ön işleme aşamasında öncelikle veri tipleri incelenmiş, eksik değerler kontrol edilmiş ve zaman bilgileri uygun tarih-saat formatına dönüştürülmüştür. Timestamp alanı kullanılarak talebin açılış ve kapanış zamanları arasındaki fark hesaplanmış ve Resolution_Time_Hours değişkeni oluşturulmuştur. Bu değişken, çözüm süresi regresyon modelinin hedef değişkenidir.

Olay kayıtlarından süreç davranışını temsil eden yeni özellikler türetilmiştir. Step_count, bir dosyanın süreç boyunca kaç adımdan geçtiğini gösterir. Reassignment_count, talebin farklı sorumlulara aktarılma durumunu temsil eder. Escalation_count, üst destek yönlendirmelerini özetler. Has_Bounce, talebin geri dönüş veya yeniden açılma gibi davranışlar içerip içermediğini gösteren ikili bir değişkendir. Workload_Index ise süreç yoğunluğunu daha bütüncül temsil etmek için oluşturulmuştur.

Bu ön işleme adımları sayesinde ham olay kayıtları, makine öğrenmesi modellerinin kullanabileceği düzenli ve vaka düzeyinde bir veri yapısına dönüştürülmüştür.

Case ID	Variant	Priority	Reporter	Timestamp	Event	Issue Type	Resolver	Report Channel	Short Description	Customer Satisfaction	
0	INC0001	Variant 4	Medium	Alice	17/11/2023 11:17	Ticket created	Performance Issue	NaN	Website	Application crash	3
1	INC0001	Variant 4	Medium	Alice	17/11/2023 13:30	Ticket assigned to level 1 support	Performance Issue	Sam	Website	Application crash	3
2	INC0001	Variant 4	Medium	Alice	17/11/2023 14:06	WIP - level 1 support	Performance Issue	Sam	Website	Application crash	3
3	INC0001	Variant 4	Medium	Alice	17/11/2023 16:52	Level 1 escalates to level 2 support	Performance Issue	Michael	Website	Application crash	3
4	INC0001	Variant 4	Medium	Alice	17/11/2023 18:07	WIP - level 2 support	Performance Issue	Emma	Website	Application crash	3

Şekil 4.1. Ham Incident Veri Setinden Örnek Kayıtlar

	Variant	Priority	Issue Type	Report Channel	Step_count	Reassignment_count	Escalation_count	Has_Bounce	Workload_Index	Open_Hour	Is_Weekend	SLA_Violation
Case ID												
INC0001	Variant 4	Medium	Performance Issue	Website	7	5	1.0	0	35	11	0	0
INC0002	Variant 3	High	Performance Issue	App	8	5	1.0	0	40	7	0	0
INC0003	Variant 9	High	Feature Request	Website	10	5	1.0	0	50	19	0	0
INC0004	Variant 1	Medium	Incident	Email	6	3	0.0	0	18	18	0	0
INC0005	Variant 3	Low	Performance Issue	Website	8	6	1.0	0	48	12	0	0

Şekil 4.2. Ön İşleme Sonrası Vaka Düzeyinde Oluşturulan Veri Seti

4.2. Kullanılan Özellikler

Modelleme sürecinde kullanılan özellikler kategorik ve sayısal olmak üzere iki grupta ele alınmıştır. Kategorik özellikler, destek talebinin türünü ve bağlamını temsil etmektedir. Priority, talebin önem derecesini ifade eder. Issue Type, talebin hata, performans problemi, servis isteği veya benzeri hangi kategoriye ait olduğunu gösterir. Report Channel, talebin hangi kanal üzerinden bildirildiğini belirtir. Variant ise sürecin izlediği farklı işlem varyantlarını temsil eder.

Sayısal özellikler ise sürecin davranışını ve operasyonel yoğunluğunu açıklamak için kullanılmıştır. Step_count, Reassignment_count, Escalation_count, Has_Bounce, Workload_Index bu özellikler arasındadır. Ayrıca Open_Hour, talebin günün hangi saatinde açıldığını; Is_Weekend ise talebin hafta sonu açılıp açılmadığını gösterir.


Bu özelliklerin seçilmesindeki temel amaç, yalnızca talebin ilk açılış bilgisini değil, süreç içinde oluşan erken sinyalleri de modele dahil etmektir. Böylece model, yalnızca “talep türüne” değil, talebin süreç boyunca nasıl ilerlediğine de bakarak tahmin üretebilmektedir.

4.3. Denetimli Öğrenme Yaklaşımı

Projede denetimli öğrenme yaklaşımı benimsenmiştir. Model giriş verileri (X) olarak seçilen özellikler kullanılmış, hedef değişken ise probleme göre değişmektedir. SLA ihlal tahmini

için hedef değişken SLA_Violation, çözüm süresi tahmini için hedef değişken Resolution_Time_Hours olarak kullanılmıştır.

Veri seti %80 eğitim ve %20 test olacak şekilde ayrılmış ve sınıf dengesizliği problemi nedeniyle stratified sampling yöntemi kullanılmıştır.



Şekil 4.4. SLA İhlal Durumuna Göre Sınıf Dağılımı

SLA ihlal riski tahmini bir sınıflandırma problemidir. Çünkü model, bir talebin ihlal yapıp yapmayacağını iki sınıf üzerinden tahmin etmektedir. Çözüm süresi tahmini ise regresyon problemidir. Çünkü model, saat cinsinden sürekli bir sayısal değer üretmektedir. Bu iki farklı denetimli öğrenme problemi, aynı veri yapısından yararlanarak farklı karar destek çıktıları üretmiştir.

4.4. SLA İhlal Riski Sınıflandırma Modeli

Sınıflandırma çalışmasında farklı modeller karşılaştırılmıştır. Dummy model, temel karşılaştırma noktası olarak kullanılmıştır. Dummy model, gerçek anlamda öğrenme yapmayan basit bir referans modeldir ve geliştirilen modellerin gerçekten anlamlı bir öğrenme sağlayıp sağlamadığını görmek için kullanılır. Logistic Regression, doğrusal yapıda çalışan ve yorumlanabilir bir sınıflandırma modelidir. Random Forest ise birden fazla karar ağacını birlikte kullanan, tabular verilerde güçlü sonuçlar verebilen bir modeldir. MLP tabanlı yapay sinir ağı modeli de geliştirilmiştir.

Random Forest modeli, arayüz entegrasyonunda risk skoru üretmek için kullanılmıştır. Modelin ürettiği olasılık değeri, düşük, orta ve yüksek risk seviyelerine dönüştürülmüştür. Bu

dönüşüm sayesinde teknik olasılık değeri, son kullanıcı için daha anlaşılır bir risk ifadesine çevrilmiştir.

4.5. Çözüm Süresi Regresyon Modeli

Çözüm süresi tahmini için Random Forest regresyon modeli kullanılmıştır. Bu model, geçmiş incident kayıtlarından öğrenerek yeni veya analiz edilen bir talep için tahmini çözüm süresi üretmektedir. Modelin çıktısı arayüzde “Tahmini Çözüm Süresi” olarak gösterilmektedir.

Regresyon çıktısı tek başına değerlendirilmemiştir. Tahmini çözüm süresi, talebin öncelik seviyesine göre belirlenen SLA limiti ile karşılaştırılmıştır. High öncelikli talepler için SLA limiti 8 saat, Medium öncelikli talepler için 24 saat, Low öncelikli talepler için ise 48 saat olarak kullanılmıştır. Böylece modelin saat cinsinden ürettiği çıktı, kullanıcı açısından “Limit içinde”, “Limitine yakın” veya “Limit aşımı bekleniyor” gibi daha anlaşılır bir duruma dönüştürülmüştür.

4.6. Yapay Sinir Ağı Modeli


Yapay sinir ağı modeli çok katmanlı perceptron (MLP) yapısında tasarlanmıştır. Model, giriş katmanı, gizli katmanlar ve çıkış katmanından oluşmaktadır.

Giriş katmanı, modelin aldığı özellikleri temsil eder. Bu projede giriş özellikleri; Priority, Issue Type, Report Channel, Variant, Step_count, Reassignment_count, Escalation_count, Has_Bounce, Workload_Index, Open_Hour ve Is_Weekend alanlarından oluşmaktadır. Kategorik değişkenler sayısallaştırılmış, sayısal değişkenler ise ölçeklendirilerek modele uygun hale getirilmiştir.

Modelde iki gizli katman kullanılmıştır. İlk gizli katmanda 64 nöron, ikinci gizli katmanda ise 32 nöron bulunmaktadır. Gizli katmanlarda ReLU aktivasyon fonksiyonu tercih edilmiştir. Aktivasyon fonksiyonu, nöron çıktısının nasıl dönüştürüleceğini belirleyen yapıdır. ReLU, negatif değerleri sıfıra yaklaştırıp pozitif değerleri koruduğu için çok katmanlı ağlarda yaygın olarak kullanılır.

Modelde aşırı öğrenmeyi azaltmak için dropout katmanları kullanılmıştır. Aşırı öğrenme, modelin eğitim verisini ezberleyip yeni verilerde daha düşük performans göstermesi durumudur. Dropout, eğitim sırasında bazı nöronları rastgele devre dışı bırakarak modelin daha genellenebilir öğrenmesine yardımcı olur.

Çıkış katmanında tek nöron ve sigmoid aktivasyon fonksiyonu kullanılmıştır. Sigmoid fonksiyonu, çıktıyı 0 ile 1 arasında bir olasılık değerine dönüştürür. Bu nedenle ikili sınıflandırma problemleri için uygundur. Modelin kayıp fonksiyonu binary crossentropy olarak belirlenmiştir. Binary crossentropy, ikili sınıflandırma problemlerinde model tahmini ile gerçek sınıf arasındaki hatayı ölçmek için kullanılır.



Şekil 4.5. Yapay Sinir Ağı Modelinin Genel Mimarisi ve Eğitim Süreci

Eğitim sürecinde Adam optimizier kullanılmıştır. Optimizier, model ağırlıklarının eğitim sırasında nasıl güncelleneceğini belirleyen yöntemdir. Ayrıca EarlyStopping uygulanmıştır. EarlyStopping, doğrulama kaybı belirli bir süre iyileşmediğinde eğitimi durdurarak aşırı öğrenme riskini azaltır. Sınıf dengesizliği nedeniyle class_weight yöntemi de kullanılmıştır. Bu yöntem, azınlık sınıfı olan SLA ihlali örneklerinin eğitim sırasında daha fazla dikkate alınmasını sağlar.

4.7. Model Çıktılarının Arayüze Entegrasyonu

Arayüzde config dosyaları kullanılarak modelin beklediği özellikler, risk eşikleri ve SLA limitleri yönetilmektedir. Risk modeli için düşük ve yüksek risk eşikleri, süre modeli için ise tahmin sütunu ve model özellikleri config dosyalarından okunmaktadır.

SLA ihlal olasılığı yüzde risk skoruna dönüştürülmüştür. Risk skoru düşük, orta ve yüksek risk seviyelerine ayrılmıştır.

Tahmini çözüm süresi, SLA limitiyle karşılaştırılmış ve SLA durumu oluşturulmuştur. Ayrıca süreç göstergelerine göre önerilen aksiyon üretilmiştir.

Bu entegrasyon sayesinde model çıktıları yalnızca teknik bir analiz sonucu olmaktan çıkmış, IT servis yönetimi için kullanılabilir bir karar destek paneline dönüştürülmüştür.

5. TEST VE DOĞRULAMA

5.1. Sınıflandırma Modeli Sonuçları


Model performansını değerlendirmek amacıyla accuracy, precision, recall, F1-score ve ROC-AUC gibi metrikler kullanılmıştır.

Bu metrikler, modelin farklı açılardan performansını analiz etmeye olanak sağlamıştır. Accuracy, tüm doğru tahminlerin oranını gösterir; ancak SLA ihlali sınıfı azınlıkta olduğunda model çoğunluk sınıfını tahmin ederek yüksek accuracy elde edebilir. Precision, modelin “ihlal” dediği kayıtların ne kadarının gerçekten ihlal olduğunu gösterir. Recall, gerçek ihlallerin ne kadarının model tarafından yakalandığını ifade eder. F1-score ise precision ve recall değerlerini birlikte değerlendiren dengeli bir metriktir. ROC-AUC ise farklı karar eşiklerinde modelin iki sınıfı ayırma gücünü özetler.

Bu proje açısından recall metriği önemlidir. Çünkü gerçek SLA ihlallerinin mümkün olduğunca erken yakalanması, operasyonel müdahale açısından değerlidir. Ancak yalnızca recall değerini artırmak da yeterli değildir; çok fazla yanlış alarm üretmek kullanıcıyı yorabilir. Bu nedenle F1-score ve ROC-AUC değerleriyle birlikte değerlendirme yapılması daha sağlıklı bir yaklaşım oluşturmuştur.

5.2. Regresyon Modeli Sonuçları

Modelin başarısını değerlendirmek için MAE, RMSE ve R^2 metrikleri kullanılmıştır.




Şekil 5.1. Gerçek ve Tahmin Edilen Çözüm Sürelerinin Karşılaştırılması

MAE değeri 1,5582 saat olarak elde edilmiştir. MAE, modelin tahminlerinin gerçek çözüm süresinden ortalama mutlak sapmasını gösterir. Bu değerin yaklaşık 1,56 saat olması, modelin genel hata düzeyinin operasyonel yorum için kullanılabilir bir aralıkta olduğunu göstermektedir.

RMSE değeri 2,0975 saat olarak hesaplanmıştır. RMSE, büyük hatalara MAE'ye göre daha duyarlı bir metriktir. RMSE değerinin MAE'den yüksek olması, bazı kayıtlarda daha büyük tahmin hataları bulunabileceğini göstermektedir. Bu durum, özellikle sıra dışı veya süreç davranışı karmaşık olan taleplerin model tarafından daha zor tahmin edilebildiğini düşündürülebilir.


R^2 değeri 0,9258 olarak elde edilmiştir. R^2 , modelin çözüm süresindeki değişimin ne kadarını açıklayabildiğini gösterir. Bu değer yüksek olması, kullanılan özelliklerin çözüm süresiyle güçlü bir ilişki kurduğunu göstermektedir.



Şekil 5.2. Regresyon Modeline Ait Tahmin Hatası Dağılımı

5.3. Yapay Sinir Ağı Model Sonuçları


Yapay sinir ağı modelinin eğitim süreci boyunca loss ve accuracy değerleri takip edilmiştir. Loss değeri, modelin tahminleri ile gerçek değerler arasındaki hatayı temsil eder. Eğitim sürecinde loss değerinin azalması, modelin eğitim verisindeki örüntüleri öğrendiğini gösterir. Accuracy ise modelin doğru sınıflandırma oranını ifade eder.



Şekil 5.3. Yapay Sinir Ağı Modelinin Eğitim ve Doğrulama Süreci

Modelin yalnızca eğitim verisindeki başarısı yeterli değildir. Bu nedenle validation loss ve validation accuracy değerleri de izlenmiştir. Validation değerleri, modelin eğitim sırasında görmediği doğrulama verisi üzerindeki performansını gösterir. Eğitim loss değeri azalırken validation loss değeri artmaya başlarsa bu durum overfitting belirtisi olabilir.

Bu projede EarlyStopping kullanılarak overfitting riski azaltılmaya çalışılmıştır. EarlyStopping, doğrulama kaybı belirli bir süre iyileşmediğinde eğitimi durdurur ve en iyi ağırlıkları geri yükler. Ayrıca dropout katmanları ile modelin eğitim verisini ezberleme eğilimi azaltılmıştır.



Şekil 5.4. Yapay Sinir Ağı Modeline Ait ROC Eğrisi

Yapay sinir ağı modeli, önemli bir modelleme yaklaşımı sunmaktadır. Ancak tabular veri yapısında her zaman en iyi sonucu vermeyebilir. Bu nedenle YSA modeli, Random Forest ve Logistic Regression gibi modellerle karşılaştırmalı olarak değerlendirilmiştir.

5.4. Modellerin Karşılaştırılması


	Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
3	Random Forest	0.9620	0.5185	0.6857	0.5905	0.9697
0	YSA / MLP	0.9053	0.2945	0.9796	0.4528	0.9788
2	Logistic Regression	0.9012	0.2867	0.9878	0.4444	0.9790
1	Dummy Baseline	0.9600	0.0000	0.0000	0.0000	0.5000

Tablo 5.5. Modellerinin Performans Karşılaştırması

Projede Dummy model, Logistic Regression, Random Forest ve Yapay Sinir Ağı modeli karşılaştırma amacıyla ele alınmıştır. Dummy model, temel referans noktası olarak kullanılmıştır. Bu model, gerçek öğrenme yapmadığı için diğer modellerin gerçekten anlamlı bir iyileşme sağlayıp sağlamadığını görmek açısından önemlidir.

Logistic Regression, doğrusal karar sınırına dayanan ve yorumlanabilirliği yüksek bir modeldir. Ancak IT servis süreçleri gibi çok sayıda kategorik ve süreç tabanlı değişken içeren problemlerde doğrusal ilişkiler her zaman yeterli olmayabilir. Random Forest ise birden fazla karar ağacını bir araya getirerek daha karmaşık ilişkileri yakalayabilmektedir. Bu nedenle tabular veri yapısında güçlü bir alternatif olarak öne çıkmaktadır.

Yapay sinir ağı modeli, çok katmanlı yapısı sayesinde doğrusal olmayan ilişkileri öğrenebilme potansiyeline sahiptir. Ancak YSA modelleri, veri yapısına, özellik sayısına, sınıf dengesizliğine ve hiperparametre seçimlerine duyarlıdır. Bu nedenle YSA'nın Random Forest'tan daha düşük performans göstermesi doğrudan başarısızlık olarak yorumlanmamalıdır. Bu durum, tabular veri problemlerinde ağaç tabanlı modellerin bazı durumlarda daha uygun olabileceğini göstermektedir.



Şekil 5.6. Modellerin ROC-AUC Performans Karşılaştırması

6. SONUÇ VE DEĞERLENDİRME

6.1. Proje Sonuçları

Bu proje kapsamında IT servis yönetimi verileri kullanılarak SLA ihlal riski tahmini ve çözüm süresi öngörüsü yapan bir karar destek sistemi geliştirilmiştir. Proje, hem sınıflandırma hem de regresyon problemini içermesi açısından kapsamlı bir denetimli öğrenme uygulamasıdır.

6.2. Yapay Sinir Ağları Açısından Değerlendirme

Yapay sinir ağı modeli, karmaşık ilişkileri öğrenme konusunda başarılı performans göstermiştir. Ancak bazı durumlarda Random Forest gibi modeller ile benzer veya daha düşük performans sergileyebilmektedir. Bu durum, veri yapısına bağlı olarak model seçiminin önemini ortaya koymaktadır.

6.3. Sınırlılıklar ve Gelecek Çalışmalar

Projede veri dengesizliği önemli bir sınırlılık olarak karşımıza çıkmaktadır. Ayrıca kullanılan özelliklerin artırılması ve daha büyük veri setleri ile çalışılması model performansını artırabilir. Gelecek çalışmalarda derin öğrenme yöntemleri ve gerçek zamanlı sistem entegrasyonu üzerine çalışmalar yapılabilir.

KAYNAKLAR

- [1] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, É. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830. Eriřim adresi: <https://scikit-learn.org/stable/>
- [2] Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., ... Zheng, X. (2016). *TensorFlow: Large-scale machine learning on heterogeneous systems*. Eriřim adresi: <https://www.tensorflow.org/>
- [3] Chollet, F. (2015). *Keras*. Eriřim adresi: <https://keras.io/>
- [4] McKinney, W. (2010). *Data Structures for Statistical Computing in Python*. Proceedings of the 9th Python in Science Conference. Eriřim adresi: <https://pandas.pydata.org/>
- [5] Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., ... Oliphant, T. E. (2020). *Array programming with NumPy*. Nature, 585, 357–362. Eriřim adresi: <https://numpy.org/>
- [6] Hunter, J. D. (2007). *Matplotlib: A 2D Graphics Environment*. Computing in Science & Engineering, 9(3), 90–95. Eriřim adresi: <https://matplotlib.org/>
- [7] Waskom, M. (2021). *Seaborn: Statistical Data Visualization*. Journal of Open Source Software. Eriřim adresi: <https://seaborn.pydata.org/>
- [8] Alpaydın, E. (2014). *Introduction to Machine Learning*. MIT Press.
- [9] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- [10] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

8. GİTHUB LİNKİ

<https://github.com/azraisik/yapay-sinir-aglari>